



Vilniaus Universitetas

2. Laiko eilučių koreliacinės funkcijos

Darbą atliko:

Vainius Gataveckas, Matas Gaulia, Dovydas Martinkus

Duomenų Mokslas

3 kursas 2 gr.

vainius.gataveckas@mif.stud.vu.lt

matas.gaulia@mif.stud.vu.lt

dovydas.martinkus@mif.stud.vu.lt

Vilnius, 2022

Turinys

Ivadas	3
Duomenys	4
ACF	7
PACF	8
ACF ir PACF.....	9
CCF	10
EACF	11
Šaltiniai.....	12

Įvadas

Laiko eilučių teorijoje autoregresinių (AR), slenkančio vidurkio (MA) ir autoregresinio slenkančio vidurkio (ARMA) procesų eilės nustatymui pasitelkiami koreliacijų skaičiavimo metodai. MA q eilės nustatymui pasitelkiamas autokoreliacijos skaičiavimas. AR p eilės nustatymui - dalinė autokoreliacija. ARMA p ir q eilę galima įvertinti su išplėstine autokoreliacijos funkcija (angl. extended autocorrelation function). Šis darbas aptaria ir kryžminės koreliacijos metodą (angl. cross correlation function).

Metodai realizuoti R programine įranga. Naudojantis šios įrangos nupieštais grafikais galima lengviau identifikuoti tendencijas reikalingas įvertinti p ir q eiles, taip pat sezono periodo įtaką. Pateiktuose pavyzdžiuose koncentruojamės į pačius metodus ir jų skaičiavimą, t.y. netaikysime pilnos Box-Jenkins metodologijos.


Metodų panaudojimui reikalinga silpno stacionarumo prielaida. Tam pasiekti bus atliekamas duomenų diferencijavimas (skirtumų ėmimas).

Duomenys

Šiam darbui kaip pavyzdinius duomenis naudosime 2 duomenų rinkinius, abu yra jau iš karto instaliuoti su R kalba. Pirmasis duomenų rinkinys susideda iš kasmetinių Nilo upės matavimų, buvo matuojama kiek kubinių metrų vandens praplaukia pro Asuaną, stebėta tarp 1871 - 1970 metų. Antrąjį duomenų rinkinį sudaro stebėjimai kiek per metus ant saulės paviršiaus atsiranda tamsių dėmių, stebėta tarp 1700 ir 1988. Duomenis galima prieiti tiesiog per R parašius duomenų šaltinių pavadinimus.

Skaiciavimams atlikti naudojamos bibliotekos „TSA“ ir „tseries“.

```
> data <- Nile  
> plot(data, type = "l")
```



1 pav. Nilo upės duomenys.

Iš grafiko (1 pav.) atrodo, kad laiko eilutė nestacionari, patikrinsime tą su Dickey-Fuller testu.

```
> adf.test(data)
```

Augmented Dickey-Fuller Test

data: data

Dickey-Fuller = -3.3657, Lag order = 4, p-value = 0.0642

alternative hypothesis: stationary

Kadangi p reikšmė yra daugiau nei 0.05, neatmetame nulinės hipotezės, tai reiškia kad mūsų seka nėra stacionari, reikia ją diferencijuoti ir pabandyti vėl.

```
> diffNile <- diff(data, differences=1)
```

```
> adf.test(diffNile)
```


Augmented Dickey-Fuller Test

data: diffNile

Dickey-Fuller = -6.5924, Lag order = 4, p-value = 0.01

alternative hypothesis: stationary

Dabar p reikšmė yra mažiau nei 0.05, tad galime sakyti kad diferencijuota seka yra stacionari.



2 pav. Diferencijuoti Nilo upės duomenys

Antrieji duomenys yra saulės dėmių skaičius jos paviršiuje.

```
> ss <- sunspot.year  
> ss <- ss[time(ss) >= 1871 & time(ss) <= 1970]  
> plot(ss, type = "l")  
> adf.test(ss)
```


Augmented Dickey-Fuller Test

data: ss

Dickey-Fuller = -6.5954, Lag order = 4, p-value = 0.01

alternative hypothesis: stationary

Matome kad antroji laiko eilutė yra stacionari ir jos nereikia diferencijuoti.



3 pav. Saulės dėmių skaičiaus duomenys

ACF


ACF - autokoreliacijos funkcija, kuri matuoja kaip koreliuoja dabartinio momento reikšmė su praeitomis. Funkcija apibrėžta taip:

$$\rho_X = \frac{r_X(h)}{r_X(0)}$$

Kur $r(h)$ – kovariacinė funkcija, h – vėlavimo operatoriaus laipsnis.

Naudojant R galima labai paprastai gauti ACF grafiką. Funkcijos `acf()` parametras „lag.max“ nusako maksimalų h kuris bus vaizduojamas grafike.

```
> acf(diffNile, lag.max = 100)
```



4 pav. Nilo duomenų ACF grafikas

Grafike matoma punktyrinė linija yra statistškai reikšmingų korelacių riba su hipoteze $\rho = 0$. Taip pat matoma silpstanti sinusoidė susidaranti iš korelacių reikšmių. Toks korelacių elgesys nėra išskirtinis.

Šis grafikas yra naudingas tame, kad galime surasti slenkančio vidurkio komponentės reikšmę, reikia ieškoti pirmos vėlavimo operatoriaus reikšmės, kuri statistškai reikšmingai nekoreliuoja su dabartiniu laiko momentu.

Taigi iš grafiko galime matyti, kad vėlavimo operatorius 2 yra pirmasis, kuris statistškai reikšmingai nebepriklauso nuo tuometinio momento, iš to galime daryti išvadą, kad mūsų seką galima modeliuoti su slenkančio vidurkio eile 1. Gauname MA(1).


PACF

PACF - dalinė autokoreliacijos funkcija (angl. partial Autocorrelation function). Ši funkcija yra dalinė, nes priešingai negu ACF, ji matuoja tik koreliaciją tarp 2 laiko momentų, eliminuodama įtaką iš praeities laiko momentų koreliacijai.

$$PACF(T_i, k) = \frac{Cov((T_i | T_{(i-1)}, T_{(i-2)} \dots T_{(i-k+1)}), (T_{(i-k)} | T_{(i-1)}, T_{(i-2)} \dots T_{(i-k+1)}))}{\sigma_{(T_i | T_{(i-1)}, T_{(i-2)} \dots T_{(i-k+1)})} \times \sigma_{(T_{(i-k)} | T_{(i-1)}, T_{(i-2)} \dots T_{(i-k+1)})}}$$

Kur $T(i)$ yra laiko eilutė, o σ – standartinis nuokrypis

```
> pacf(diffNile, lag.max = 100)
```




5 pav. PACF grafikas

PACF grafikas padeda nustatyti AR modelių eilę. Lygiai tokiu pačiu principu, kaip ACF, galime teigti, kad 3-asis vėlavimo operatorius yra statistiškai nereikšmingas, todėl seką galime modeliuoti su AR(2).

ACF ir PACF

Bendroju atveju reikėtų naudoti abu metodus. Pasinaudojus gautais rezultatais (4 ir 5 pav.) sekai modeliuoti turime kelis pasirinkimus: MA(1), AR(2). Priimtina modeliuoti paprasčiausią įmanomą modelį.

Atlikus tuos pačius veiksmus su „sunspots“ duomenimis, kuriuose yra sezonas gaunama ryškesnė sinusoidė.



6 pav. Saulės dėmių duomenys. ACF ir PACF

Egzistuojant sezoniskumo komponentei ACF grafike koreliacijos nėra lygios nuliui $i*s$ vėlavimams, kai $i = 1, 2, 3, \dots$, o s yra sezono periodas. Atsižvelgus į sezono įtaką - prieš tai aptartos eilės įvertinimo taisyklės galioja lygiai taip pat.

CCF

CCF – kryžminė koreliacijos funkcija (angl. cross correlation function) matuojanti kaip koreliuoja laiko eilutė su kitos laiko eilutės teigiamai ir neigiamais vėlavimais.

Formulė:


$$CCF(x, y, h) = corr(x(t), y(t + h))$$

Kur $x(t)$ ir $y(t)$ laiko eilutės, o h – vėlavimo operatorius

```
> ccfval <- ccf(c(data), ss, lag.max = 10, main = "CCF")  
> ccfval
```

Autocorrelations of series 'X', by lag

-10	-9	-8	-7	-6	-5	-4	-3	-2	
-0.079	-0.099	-0.209	-0.288	-0.284	-0.245	-0.188	-0.067	-0.014	
-1	0	1	2	3	4	5	6	7	
0.017	-0.014	-0.034	-0.054	-0.058	-0.072	-0.029	-0.018	0.051	
	8	9	10						
	0.019	-0.026	-0.058						



Matome kad su vėlavimo operatoriaus reikšmėmis -6 ir -7 gauname stipriausias koreliacijas, o su operatoriumi -8, -7, -6, -5 tiesiog statistiškai reikšmingas koreliacijas.

EACF

EACF – išplėsta autokoreliacijos funkcija (angl. Extended AutoCorrelation Function). Tai funkcija padedanti surasti geriausias ARMA modelio p ir q reikšmės.

Kadangi tikrinant ACF ir PACF funkcijas atskirai gaunami rezultatai apie AR ir MA yra irgi atskiri, tad EACF padeda modeliuoti juos kartu padėdamas surasti ARMA proceso paramterus.

Vykdant funkciją reikia nurodyti laiko eilutę ir maksimalias AR ir MA modelių parametrų reikšmės, tuomet kiekvienai kombinacijai bus parašoma ar autokoreliacija reikšminga su simboliu „x“ ar nereikšminga su simboliu „o“.

```
> eacf(diffNile, 5, 5)
```

```
AR/MA
```

```
  0 1 2 3 4 5
```

```
0 x o o o o o
```

```
1 x x o o o o
```

```
2 x o o o o o
```

```
3 x x x o o o
```

```
4 x x x o o o
```

```
5 x o x o x o
```

Gavus lentelę reikia ieškoti simboliu „o“ apsuptų kuo daugiau „x“, taigi galimi variantai yra:

ARMA(0, 1)

ARMA(2, 1)

ARMA(5, 1)

Šios kombinacijos taip pat kodo rezultatuose nuspelvintos geltona spalva.

Šaltiniai

Taikomoji laiko eilučių ekonometrija. V. Kvedaras, 2005,
http://web.vu.lt/mif/v.kvedaras/files/2013/09/Konspektas_2005.pdf
R Project. R. Schulz, 2006,
http://sfb649.wiwi.hu-berlin.de/fedc_homepage/xplore/help/eacf.html
Cross Correlation ,Paul Bourke, 1996,
<http://paulbourke.net/miscellaneous/correlate/>